1 目标、实现范围与实验设计

GB1 科学智能体扩展实验报告

本阶段完成六项扩展内容：主动学习、不确定性估计、突变数量比较、结构信息、知识图谱和自动化平台对接讨论。主动学习选择采集策略比较路线，结构信息选择参考结构特征路线；交互式 Demo 由后续完成的 DSH 插件提供，不在本阶段范围内。没有开展真实湿实验，也没有训练大型蛋白质模型。

扩展内容	实际实现与检查
主动学习	random、greedy、std_only、mean_plus_std，选后反馈、各臂独立重训
不确定性	100 棵树预测分歧；独立绝对/尺度残差校准；覆盖率与宽度
突变数量	HD1、2、3、4 各 40 候选，随机与主动策略同预算比较
结构	1PGA 参考距离、近邻阈值敏感性、100/960 点 SASA
知识图谱	带来源有向图、查询与保存恢复；真实 Agent 增强对照
平台讨论	SiLA2/Opentrons 接口、状态、数据、质量和异常流程

数据采用 Wu 等人的 S1，149,361 条测量/校准记录，S2 插补表不纳入。[1] 使用新拆分种子 44、55、66；每组训练 2,000 条含 WT、16 条单点及 1,983 条 HD≥2，随机共同留出 6,000 条再分校准 1,000/测试 5,000，其余 141,361 条作候选。抽取不按 fitness 筛选，并预留至少 40 条单点候选。

预测器固定为 100 棵树 Random Forest、叶样本最少 1、4 线程，不在新校准/测试标签上选择参数。全部控制器只在选定候选后取得 S1 分数。全池 4 策略与 HD 分组 8 策略，每种子 12 臂、各 3 轮 Top-10，共 108 轮、1,080 条虚拟查询。图谱 Agent 另有 6 条件、60 条推荐。

新拆分没有用于此前提示调整，但仍来自同一公开蛋白数据；结果不代表跨蛋白泛化。独立校准与测试角色、候选资格、模型版本和运行参数均保存在文件中。

2 主动选样与不确定性评价

设森林预测均值为 μ，100 棵树预测的样本标准差为 s。四种策略分别均匀随机、按 μ、按 s、按 μ+s 选样。系数 1 为预先固定的探索设置，不宣称最优或满足 GP-UCB 理论条件。[2] 每轮各方法仅加入自身 10 条新反馈，再重新训练。

全池策略	30 条推荐均值 ± SD	30 次查询后的最高新增 ± SD
随机	0.059 ± 0.020	1.027 ± 0.332
预测均值	3.419 ± 0.694	7.256 ± 0.315
集成分歧	2.220 ± 0.643	7.294 ± 1.437
均值 + 分歧	3.479 ± 0.313	7.867 ± 0.787

s 仅是集成分歧。用独立校准样本分别计算|y−μ|及|y−μ|/max(s,1e−6)，取排序后的第 ceil((n+1)×0.9) 项作为阈值，构造 90%预测区间，下界按非负 fitness 截到 0。每次重训后重新校准；采集分数不使用校准或测试标签。[3,4]

初始随机留出测试	实测覆盖率	平均区间宽度
绝对残差区间	90.7%	0.209
尺度残差区间	89.9%	0.245

初始误差绝对值与树间分歧的 Spearman 均值为 0.818。表中覆盖率是三个 5,000 条随机留出测试的均值；宽度单位为 S1 fitness。原始分歧没有被直接称为置信区间。

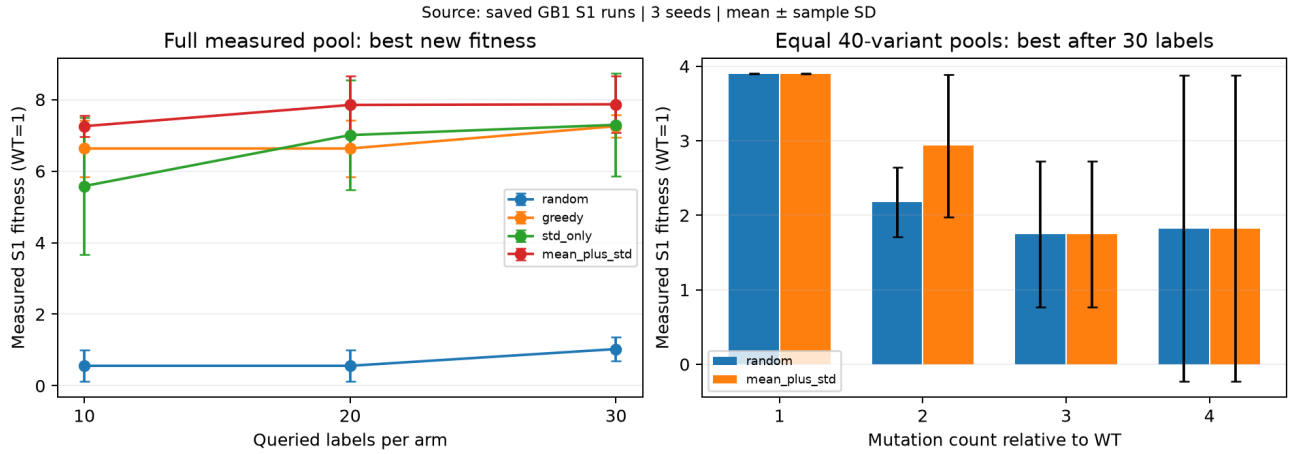
策略	最终测试尺度覆盖	选中点尺度覆盖	选中点尺度区间宽度
随机	89.4%	94.4%	0.245
预测均值	90.0%	80.0%	6.684
集成分歧	89.7%	92.2%	7.864
均值 + 分歧	90.0%	91.1%	8.037

均值 + 分歧选中点的绝对残差区间覆盖仅 6.7%；尺度区间覆盖 91.1%，但宽度达 8.037。主动选择改变分布，普通 split-conformal 边际条件不能直接用于选中点。[4] 高覆盖不能单独表示高精度；HD 分层测试有极少或空样本，原表保留其 n。

3 突变数量比较与参考结构

HD 为四个位点相对 VDGV 的不同字母数。各 HD 候选库均随机抽取 40 条，每策略三轮查询 30 条；训练数据相同，反馈独立。比较新增候选最高值，并在组内定义累计最佳，避免其他突变组的高分掩盖当前组。

HD	随机：最高新增均值 ± SD	均值 + 分歧：最高新增均值 ± SD
1	3.898 ± 0.006	3.898 ± 0.006
2	2.176 ± 0.470	2.932 ± 0.954
3	1.746 ± 0.976	1.746 ± 0.976
4	1.823 ± 2.056	1.823 ± 2.056



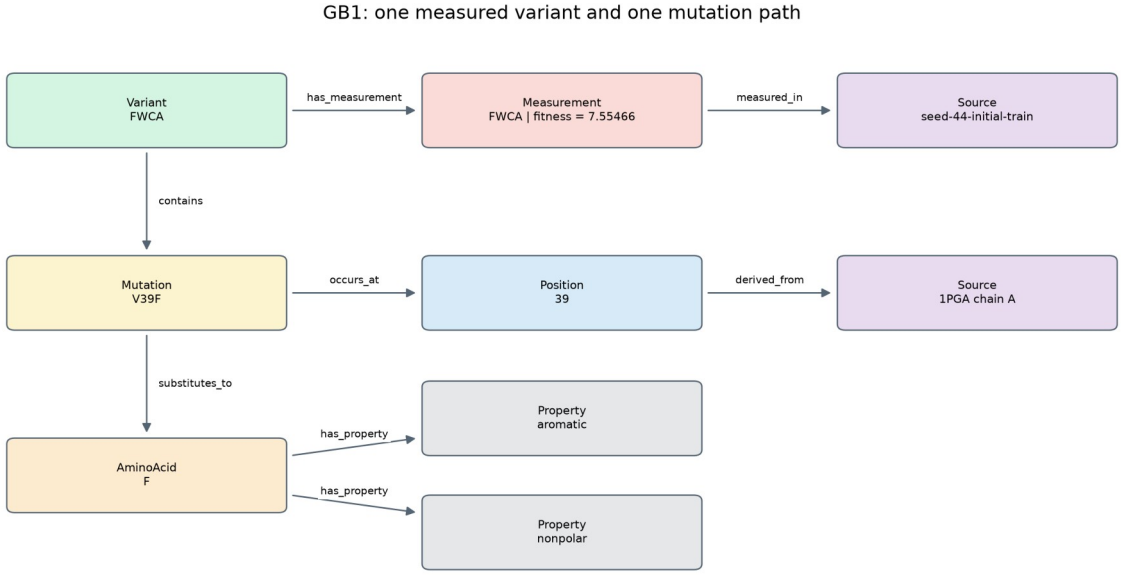
不同 HD 原始空间规模、训练覆盖和测量来源有差异，单点分数包含跨研究校准。因此这里评价同规模抽样库内的效果，不把差异全部解释为突变数量的因果作用。

位点	SASA 960 点 / Å²	4.5 Å 非相邻邻居数
39	11.824	8
40	130.237	2
41	28.373	5
54	0.978	10

使用 1PGA chain A 标准残基，剔除水及 hetero 记录。计算 Cα 与最小重原子距离，并比较 4.0/4.5/5.0 Å 近邻阈值；SASA 使用 1.4 Å probe 及 100/960 点。39–54、41–54 最小重原子距离约 3.810 和 3.670 Å。这些是参考结构几何，不是突变体结构或 fitness 因果。[5]

4 可查询知识图谱及 Agent 对照

用 NetworkX MultiDiGraph 表示 Position、Mutation、AminoAcid、Property、Variant、Measurement 和 Source。每种子图恰有 2,000 个已知测量节点，校准、测试及未查询候选分数不进入图。未知候选可查询化学和结构事实，但 fitness 状态为 unknown。[6]



图示为一个已知完整变体及一个突变路径；测量属于完整变体，不能归因于图中的单个替换。完整图 JSON 与查询来源单独保存。每种子执行 4 个位点、6 个距离对和 3 个已知观察查询，再将结果加入 Agent 上下文。

种子	静态规则均值	结构 + 图谱均值	差值
44	4.893	4.559	-0.334
55	5.277	4.764	-0.513
66	4.567	4.453	-0.113

图增强条件的 90/120 个有效候选引用了图查询事实 ID，其中 4 个引用结构事实。六条件都实际生成并评分 40 个候选、推荐 10 个；同一训练、初始 RF、v3 提示及候选范围配对。

该实验测试结构与图查询知识的组合，不能单独归因于图存储格式。性能变化如表所示，保留下降结果；实现可查询知识和模型引用，并不保证推荐性能提高。

5 平台对接、完成情况与限制

真实平台对接按软件职责讨论：候选检查 → 人工审核批次 → 适配器提交 → 保存执行 ID → 查询状态 → 导入原始测量 → 单位/映射/质量检查 → 接受结果 → 更新已知数据。SiLA 2 提供 Feature/Command/Property 及 Observable Command 执行 UUID；Opentrons 提供运行、状态和数据文件 API，具体测量能力依设备模块与协议。[7,8]

本项目需要维护 experiment/batch/operation ID、variant 与 sample 映射、协议及接口版本、原始值和单位、QC 状态、fitness 归一化版本。提交超时先核对外部执行状态，不能盲重发；仪器失败不记为蛋白质 fitness 为 0。只有被接受的结果用于训练。完整讨论已交付，未连接设备或执行湿实验。

六项扩展内容完成状态

主动选样已运行；不确定性已校准和评估；单/双/三/四点已对照；参考结构特征已计算并进入 Agent 知识；图谱已保存、查询和实际接入；自动化平台讨论已完成。交互式 Demo 由后续完成的 DSH 插件提供（当前版本 0.5.0，支持一键准备运行、批量比较与暂停恢复）。

本地 CPU 实验 108 轮、1,080 条推荐不调用 LLM。结构图谱对照实际 11 次 API 请求、142,187 tokens，未超过 12 次上限；模型请求/返回标识为 gpt-6-luna。完整离线测试 268 项通过，真实输入和结果另有独立核查。

局限与下一步研究：仅一个公开蛋白及三种子；自适应选样覆盖没有普通随机留出保证；HD 样本库大小及来源不等同；结构为孤立 WT 参照且 pos2 与实验模板不同；图增强增加上下文和知识，不能单独证明图格式贡献。所有结论以本次记录为准，不预设新方法胜出。

复现：requirements-bonus 保留原依赖并增加 Biopython/NetworkX；run_bonus.py 负责 prepare/run/summarize，run_graph_agent.py 负责 prepare/run/compare。配置、模型、选前分数与区间、选后反馈、图 JSON、查询和响应均保存，旧结果不覆盖。

主要参考

[1] Wu NC et al. eLife 2016;5:e16965. doi:10.7554/eLife.16965.

[2] Srinivas et al. GP optimization in the bandit setting, ICML 2010, arXiv:0912.3995（方法启发，未声称 GP 理论界）.

[3] Angelopoulos & Bates. Conformal prediction introduction, arXiv:2107.07511, §2.2–2.3.

[4] Wager et al. JMLR 2014;15:1625–1651；Prinster et al. JAWS-X, ICML 2023, PMLR 202.

[5] RCSB 1PGA；Biopython Bio.PDB.SASA 官方文档，Shrake–Rupley 方法.

[6] NetworkX MultiDiGraph 与 node-link 文档；OpenStax Biology 2e §3.4.

[7] sila-standard.com/standards/；SiLA Python Observable Command 官方文档.

[8] docs.opentrons.com/http/api_reference.html、python-api/versioning/及读板数据说明.

资料核查由 GPT-6 Luna 辅助，后端由 GPT-6.1 Sol 辅助，主代理负责方案、审查和文稿。文献链接、数据用途与模型辅助方式在实施方案及平台讨论中详细记录。