1 背景、数据与问题定义

面向蛋白质定向进化的科学智能体

本实验用公开 GB1 四位点数据模拟实验反馈，比较随机推荐、适应度模型推荐、LLM Agent 和知识增强 Agent。研究问题是：在相同实验标签查询预算和模型评分上限下，LLM 的候选设计及知识提示能否改善推荐结果。全部结果来自实际运行，未进行湿实验。

数据来源为 Wu 等人的 eLife 研究 Supplementary file 1 [1]。表中 149,361 条变体唯一且可解析，29,477 条 fitness 为零；零值保留，S2 插补表不纳入。76 条单点记录包含 Olson 等人实验数据的校准。分数是相对野生型的结合选择相关表现，WT=1，数值越高越好。

项目	本次设置
实验位点	39、40、41、54；野生型四字母 VDGV
初始训练 / 验证 / 最终测试	2,000 / 1,000 / 5,000 条，各部分互不重叠
隐藏候选池	141,361 条，每轮只揭示选定候选标签
重复和迭代	随机种子 11、22、33；四方法各三轮
每轮预算	最多 40 次模型评分，10 次标签查询

实验模板根据原论文 Figure 1 supplement 1 翻译，为 56 aa；第 2 位为 Q。结构参照 1PGA 的第 2 位 T 不用于候选还原。

MQYKLILNGKTLKGETTTEAVDAATAEKVFKQYANDNGVDGEWTYDDATKTFTVTE

每组划分在完整测量表上随机产生，不按 fitness 筛选。四种方法使用相同初始数据；每种方法的新增反馈只进入自己的下一轮训练。独立最终测试在三轮结束后才打开。公开数据可能被 LLM 预训练接触，本实验只保证本次流程不提前提供隐藏标签。

2 适应度模型、Agent 与知识增强

四个变异位点编码为 80 维 one-hot。每种子比较七组配置：Ridge 的 alpha=0.1/1/10；Random Forest 与 Extra Trees 各使用 100 棵树，叶节点最少样本数为 1 或 3。按验证集 Spearman、Top-10 命中率、较低 MSE 依次选择，不使用最终测试集调参。[2]

种子	选定模型 / 叶样本数	验证 Spearman	验证 MSE	Top-10 命中
11	Random Forest / 1	0.544	0.093	50%
22	Random Forest / 1	0.523	0.095	20%
33	Random Forest / 3	0.547	0.130	20%

每轮固定模型类别和超参数，仅用本方法新增数据重新拟合。Spearman 衡量排序关系；MSE 为平均平方误差；Top-10 命中率定义为预测前十与真实前十的交集数量除以十，同分按固定输入顺序处理。[2,3]

方法	生成与选择
随机推荐	从可测候选池随机抽 40 个，再随机选择 10 个
模型推荐	随机抽 40 个，按预测分数选择前 10 个
LLM Agent	GPT-6 Luna 自主设计最多 40 个合法组合，本地模型选前 10 个
知识增强 Agent	同一流程增加带来源的性质与上位性提示

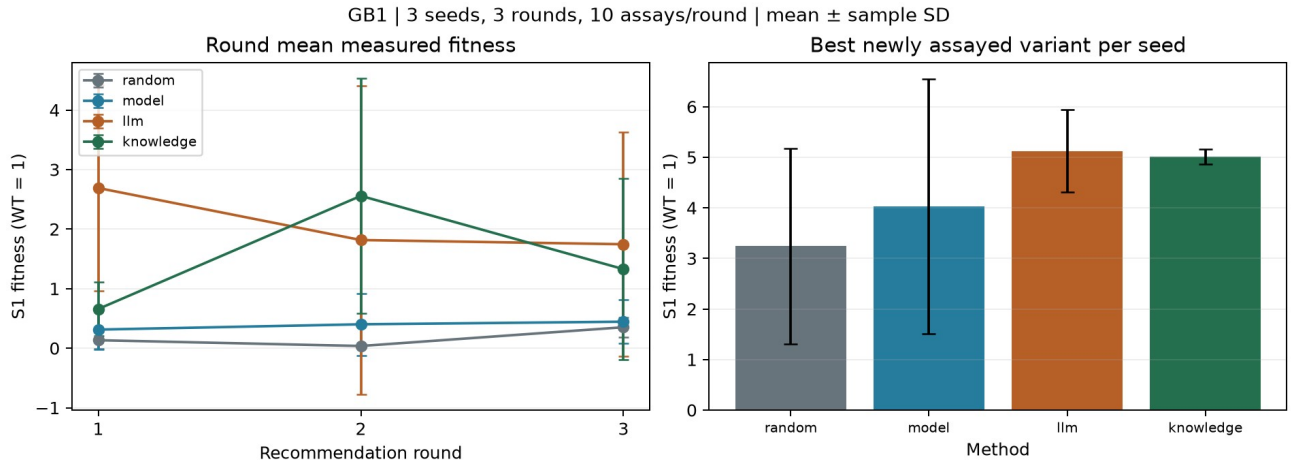
Agent 使用用户配置的 GPT-6 Luna chat API，JSON Schema 输出后经 Pydantic 检查。输入包含当前训练统计、top variants、最近反馈及无标签示例；输出包含位点分析、候选、假设与理由。Python 负责实际评分、排序、去重和隐藏评估，模型没有浏览和文件工具。[4]

知识规则引用氨基酸侧链性质、电荷、甘氨酸/脯氨酸结构区别，以及 GB1 上位性。[1,5] 规则只影响建议与解释，不改变合法范围。每轮最多一次纠正请求；不以随机候选补足 LLM 输出。评分少于 40 时照实记录。该对照评价固定评分预算下的候选生成，未将模型方法设置为全池穷举。

3 三轮对照结果

方法	第 1 轮均值	第 2 轮均值	第 3 轮均值
随机推荐	0.134 ± 0.141	0.037 ± 0.030	0.352 ± 0.169
模型推荐	0.312 ± 0.338	0.401 ± 0.520	0.445 ± 0.369
LLM Agent	2.690 ± 1.725	1.816 ± 2.590	1.746 ± 1.882
知识增强 Agent	0.658 ± 0.451	2.558 ± 1.978	1.328 ± 1.524

表中为每轮 10 个推荐的实测均值，再对三个种子计算平均值 ± 样本标准差。误差范围描述三次运行波动，不表示稳定的统计显著性。



方法	三轮新发现最佳	超过初始最佳的种子数	实测>WT 记录
随机推荐	3.241 ± 1.931	1/3	4/90
模型推荐	4.029 ± 2.521	1/3	8/90
LLM Agent	5.123 ± 0.818	1/3	48/90
知识增强 Agent	5.010 ± 0.151	2/3	40/90

新发现最佳先在每个种子的 30 个新增推荐中取最高值，再计算三种子统计。累计最佳还包含原有 2,000 条训练数据，可能在三轮中保持不变；因此同时展示新增结果。各方法最多查询 90 条记录，跨方法重复序列分别计算为各自的查询。

4 序列示例、失败分析与模型评价

方法	种子/轮	四位点	预测	实测
随机推荐	33/3	LRLG	2.095	5.041
模型推荐	33/2	IWAA	1.057	6.042
LLM Agent	11/2	WYCA	4.196	6.044
知识增强 Agent	33/3	WVFG	2.644	5.141

新增推荐最高示例：WYCA，突变为 V39W:D40Y:G41C:V54A。其完整序列：

MQYKLILNGKTLKGETTTEAVDAATAEKVFKQYANDNGWYCEWTYDDATKTFTATE

过高预测案例：知识增强 Agent，种子 22 第 2 轮的 PYGP，预测 2.034，实测 0.003。差值说明模型在该组合上判断偏高；应结合训练覆盖及组合相互作用检查，不能仅凭此案例确定生化机制。

该候选的原始推荐理由（节选）：Glycine has a small side chain, whereas proline's cyclic structure can constrain backbone geometry.

方法	最终测试 Spearman	最终测试 MSE	最终 Top-10 命中
随机推荐	0.532 ± 0.014	0.113 ± 0.008	0.033 ± 0.058
模型推荐	0.532 ± 0.011	0.111 ± 0.003	0.100 ± 0.100
LLM Agent	0.534 ± 0.010	0.109 ± 0.004	0.200 ± 0.000
知识增强 Agent	0.535 ± 0.009	0.109 ± 0.006	0.200 ± 0.000

每方法最终模型使用 2,030 条自身已知记录训练。测试评估的是同一四位点空间内的留出预测；不同随机种子的测试集可能重叠。全体每轮 Top-10、理由及完整序列保存在配套结果表，共 360 条推荐记录。

位点分布：基础 Agent 的第 41 位有 38/90 条为 C，第 54 位有 39/90 条为 A；知识增强分别偏向第 41 位 L（22/90）和第 54 位 G（36/90）。这描述候选偏好，未据此推断单点因果效应；实验只允许四个位点变化。

5 解释、复现、成本与参考来源

本次全部推荐的平均 fitness：随机推荐 0.174、模型推荐 0.386、LLM Agent 2.084、知识增强 Agent 1.515。本次三轮曲线中，基础 Agent 的均值下降，知识增强第二轮较高而第三轮下降；这说明新增推荐表现需要逐轮评价。

知识增强有 2/3 种子超过初始最佳，基础 Agent 为 1/3；推荐均值与是否刷新最佳值回答不同问题。

Agent 展示了根据当前统计和反馈提出候选的能力；其贡献需结合对照和具体假设检验判断。知识增强每轮有效候选为 10—40 个，基础 Agent 为 39—40 个，实际选择机会不同。这一运行不足已保留，不能将其影响单独归因于知识本身。

方法	总评分数	每轮有效数	API 请求	tokens
随机推荐	360	40—40	0	0
模型推荐	360	40—40	0	0
LLM Agent	358	39—40	14	121989
知识增强 Agent	285	10—40	17	175673

正式实验共 31 次 API 请求，服务返回总量 297,662 tokens；另有一次连接检查 49 tokens。实际返回模型标识为 gpt-6-luna。没有可靠价格配置，因此不推算金额。环境使用 Python3.12.14，关键依赖已固定，当前完整测试套件 268 项通过；数据划分与真实调用另有运行记录。

改进方向：单独报告全池模型评分；比较初始数据规模和训练覆盖；在独立蛋白任务上检验泛化；用新实验评估未测序列。任何新模型或依赖先查资料，再按统一划分比较。

复现：按项目 README 安装 requirements，依次运行 prepare、select、run、finalize、plot、aggregate。独立 API 需自备密钥；重新调用 LLM 可能产生不同输出，原响应已保留。代码与精选结果已发布于 GitHub 私有仓库 github.com/Yuanhang2024/gb1-scientific-agent（MIT 许可证）。后续阶段已完成 v3 提示三种子验证、多模型比较与默认值校准，结果见配套验证报告与本仓库校准报告。

后续对照（2026-11-13）：零上下文时模型可回忆出全局前十中的 2 个，但对随机批次排序 Spearman 为−0.18 至−0.27，说明预训练记忆了该公开数据的高分区域而非整表；首答候选 42%—53%落入全局前 1%，优势含记忆成分。同预算无反馈对照的均值差为+0.185、+0.121、−0.329，反馈无独立可测增益。资源限制：一周内单机 CPU 完成，ESM/GP 需 CUDA 栈未验证，主实验用 CPU 可复现的 one-hot 与树集成（见仓库 critique-followup 结果）。

参考来源与辅助工具

[1] Wu NC et al. eLife (2016), 5:e16965. doi:10.7554/eLife.16965. 数据 S1 及 Figure 1 supplement 1。

[2] scikit-learn: common_pitfalls.html；modules/grid_search.html；RandomForestRegressor 官方文档。

[3] SciPy: scipy.stats.spearmanr / pearsonr；scikit-learn: mean_squared_error。

[4] OpenAI Python SDK: github.com/openai/openai-python；Pydantic 官方 JSON Schema 文档。

[5] Clark MA, Douglas M, Choi J. Biology 2e (2018), OpenStax, §3.4 Proteins。

资料查证由 GPT-6 Luna 辅助，代码由 GPT-6.1 Sol 辅助，主代理负责设计、检查与文稿；实验数字均由已保存结果计算。