1 研究目标、数据与固定条件

GB1 科学智能体：三种子验证与详细反馈消融

本阶段检验两个问题：固定 v3 后，另外两个随机种子是否仍出现推荐改善；在已知数据和预测器相同的时刻，详细预测—实测反馈是否给下一次推荐带来额外收益。所有分数来自公开 GB1 实验表的虚拟查询，没有开展湿实验或训练大型蛋白质模型。

原始数据为 Wu 等人 S1 中的 149,361 条唯一变体，29,477 条零 fitness 保留，S2 插补表不纳入。单点记录包含先前实验的校准。目标是 IgG-Fc 结合选择相关 fitness，WT=1；四个位点为 39、40、41、54，实验域长 56 aa，模板以 MQY 开头。[1]

项目	设置
每种子的数据角色	训练 2,000；验证 1,000；隐藏候选 141,361；最终测试 5,000
固定版本验证	种子 11、22、33；两种 Agent 各三轮；每轮 Top-10
预测评分预算	每方法每轮最多 40 个有效候选；最多一次资格/格式纠正
模型比较	Ridge 三组 alpha；RF/ExtraTrees 各两种叶样本约束
选定预测器	三个种子均为 Random Forest；叶样本数 1、1、3
模型评估	验证 Spearman 为 0.5441、0.5234、0.5465

同种子 v1/v3 初始数据、模型类别和参数、预算一致；后续轮次按同样规则用各自新增反馈重训。种子 11 沿用已经完成的结果，新增种子 22 和 33 前核对了提示全文和配置。最终测试标签没有用于本次提示选择或消融输入。

GB1 是公开数据，不能排除 LLM 预训练接触。v3 是在首轮诊断后开发的，三个种子也已有历史比较；本报告属于开发性验证，不将其解释为全新盲测或跨蛋白质泛化。

2 科学 Agent 与知识使用

Agent 按观察、假设、设计、模型评分和反馈迭代组织。提示借鉴 ReAct 的行动与观察分离、Reflexion 的反馈记忆，以及机器学习辅助定向进化的方法说明。[2,3] 这些原则经本项目实际验证，不直接沿用文献中的性能数字。

环节	本实现
观察	当前方法已测统计、top/low/median 例子；不读取隐藏候选标签
假设	引用具体已知背景，给出局部预期与会削弱预期的观察
设计	首次自主生成组合；纠正阶段才提供无标签替补
模型评估	Python 实际调用固定类别预测器，评分后选 Top-10
反馈	保存原预测、真实反馈、残差 actual−predicted 与原假设
知识增强	有限的侧链性质、电荷及上位性规则，附来源和适用范围

位点边际均值不是参考背景下的单点因果效应；化学保守性也不保证提高 fitness。知识规则用于候选和解释，不改变两种方法的合法范围。API 返回经过 Pydantic、数量、重复与候选资格检查。缺额不由程序补造。

科研过程机械核查

在 360 个被评分候选的假设文本中，基础 Agent 有 283 条引用了当时可见的已测锚点（78.6%），知识增强为 344 条（95.6%）。有近期反馈的 23 次请求均至少提到一个可见反馈变体。该统计只检查文字与记录的对应，不确认假设机制正确。

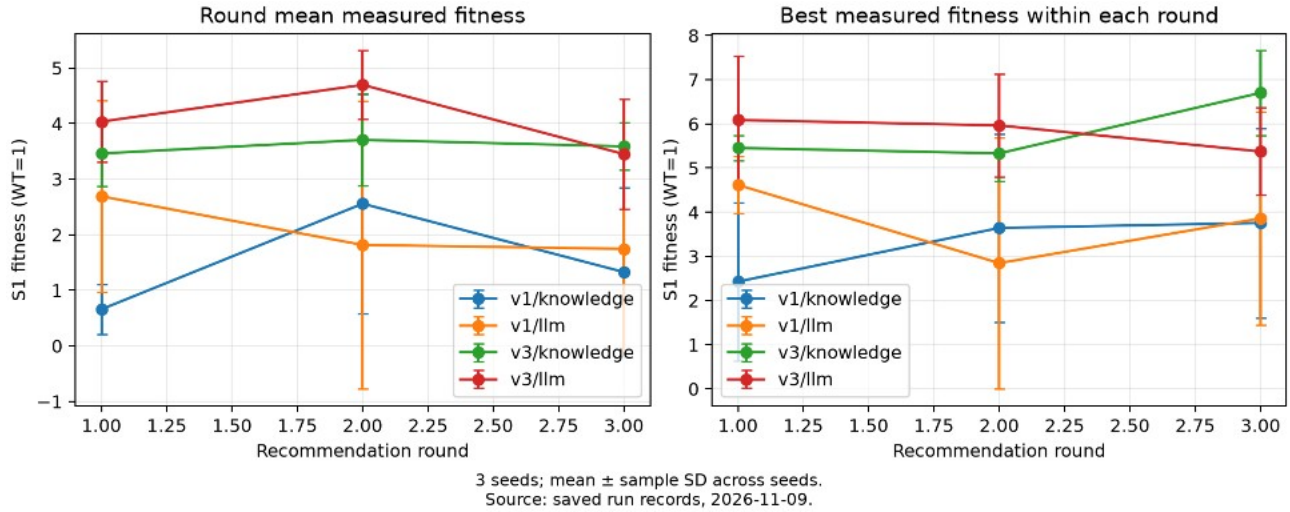
真实例子：以已测 QNCA 为锚点，把第 39 位换成 W，检验 N-C-A 组合能否在新的背景保持表现；下降会削弱该转移预期。QNCA 存在于当时的近期反馈中。Agent 的候选设计与本地预测排名分别记录，以便检查它是否仅在解释已有名单。

此前 v2 虽填满候选数量，却复制了预填随机名单，推荐表现与模型对照相同。该失败记录保留；v3 的首次请求没有可复制的候选名单。提示变详细本身不作为科学能力提高的判断依据。

3 固定 v3 的三种子结果

方法	v1 推荐均值 ± SD	v3 推荐均值 ± SD	变化为正
基础 Agent	2.084 ± 1.795	4.060 ± 0.288	3/3
知识增强	1.515 ± 1.018	3.586 ± 0.452	3/3

先对每种子三轮 30 条推荐求平均，再计算三个种子的均值与样本标准差。参考的原随机方法与模型推荐均值为 0.174 和 0.386；模型方法只评分随机抽取的 40 个候选，未穷举全池。



方法	v1 新增最高均值 ± SD	v3 新增最高均值 ± SD
基础 Agent	5.123 ± 0.818	6.175 ± 1.319
知识增强	5.010 ± 0.151	6.701 ± 0.960

v3 的 18 轮均有 40 个有效候选，共 720 次评分；v1 对应为 643 次。原数据、预算和生成方式可比较，但实际有效数量不同，效果变化不能全部归因于科研解释。v3 两方法三种子共 33 次请求、329,745 tokens，v1 为 31 次、297,662 tokens。

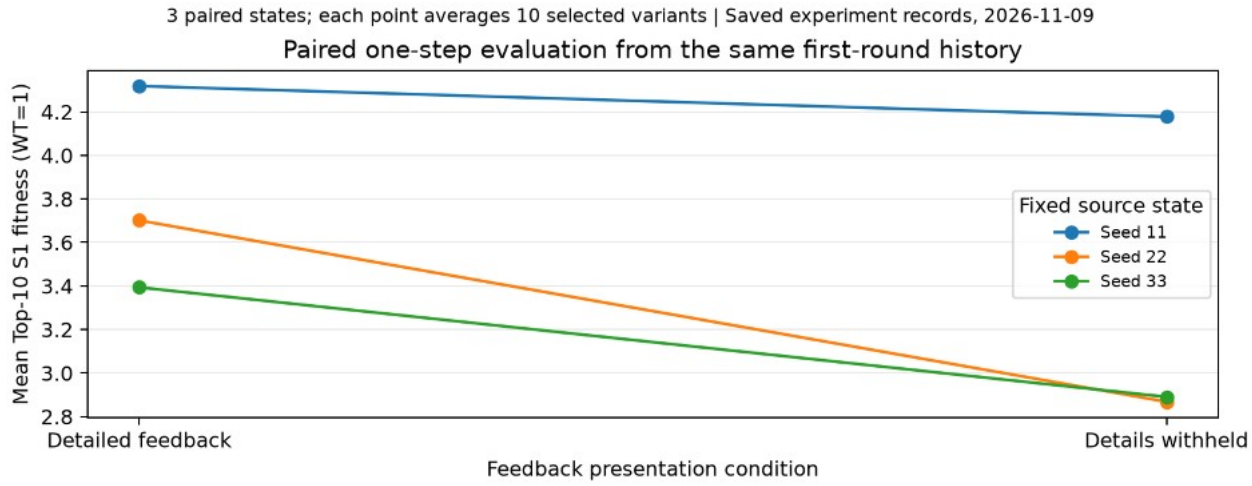
三个种子的变化方向一致，且 v3 推荐均值的跨种子波动较小；但逐轮仍有下降。知识增强的平均推荐分数低于基础 Agent，其每种子新增最高值均值更高，两个指标回答不同问题。只有三个种子，不作稳定显著优势判断。

4 详细反馈展示的配对消融

每个种子冻结知识增强方法第一轮结束后的状态：2,000 条初始训练加 10 条已揭示标签，同一个训练后的预测器供两个条件评分。两边都获得更新后的 known 摘要；full 保留逐候选预测、实际值、原假设和残差，withheld 仅隐藏这两个详细反馈字段并说明其被隐藏。其他输入、规则、schema 和候选范围相同。

两边均重新生成最多 40 个候选，由同一模型选 Top-10 后查询实验分数。各条件最多一次纠正，顺序按固定且与 fitness 无关的规则安排。第二、第三轮的源实验反馈没有加入本次输入。主指标预先定为 Top-10 实际均值，差值为 full−withheld。

种子	full 均值	withheld 均值	配对差值	推荐交集
11	4.318	4.178	+0.141	8/10
22	3.701	2.868	+0.833	0/10
33	3.394	2.890	+0.503	4/10



三个配对状态中，full 均值较高的有 3/3 组；平均配对差值为+0.492，差值的样本标准差为 0.347。本次把 seed/实验状态作为重复单位，不把 60 个被选序列视为 60 个独立重复。

最高值的变化方向不一致：种子 11 两边相同，种子 22 的隐藏条件最高值更高，种子 33 的详细反馈条件更高。平均推荐质量与找到单个更高峰值分别报告。

此消融衡量详细字段展示的条件差异；两边训练和聚合统计都保留新增数据，因此不代表全系统无反馈。删除字段也缩短输入，且 API 具有随机性；本次不能分离内容、长度与随机响应的全部作用，不计算显著性 p 值。

5 失败分析、用量与复现

一个预测偏高的 v3 案例：种子 11、llm 第 3 轮的 PWCA，预测 6.047、实测 0.047。该差异用于检查模型覆盖与组合假设，不据一个结果指定生化失效原因。

原推荐理由（节选）：High W-C-A anchors motivate a 39 transfer test, though P39 is untested here.

三轮均值没有持续上升，部分未测提议也会再次进入后续评分。后续可研究评分预算分配、候选去重与反馈表达，但应先固定比较方案，再记录正负结果。若要更强结论，应在未用于开发的条件上增加重复，并分别比较知识、反馈内容和生成约束。

本阶段工作	新增请求	返回 tokens
补齐 v3 种子 22/33	23	229,796
消融 full	6	65,229
消融 withheld	5	49,572
本阶段合计	34	344,597

本阶段预先说明的请求上限为 36 次；此前 v1/v2 与 v3 种子 11 属于已完成阶段，不计入本表。未提供可靠价格配置，故不换算金额。完整离线测试 68 项通过；真实请求、候选来源、数据范围和配对条件另行核查。

复现与交付：项目 README 记录依赖、数据获取和命令；本阶段独立入口 ablate_feedback.py 提供 prepare/run/compare。所有提示、请求和原始响应保留，旧结果未覆盖。API 重跑可能产生不同输出；GitHub 仓库尚未发布。本报告附统计摘要、推荐 CSV 及 paired_results.csv。

参考与使用说明

[1] Wu NC et al. eLife (2016), 5:e16965. doi:10.7554/eLife.16965；S1 与实际模板图。

[2] Yang KK, Wu Z, Arnold FH. Nature Methods (2019), 16:687–694. doi:10.1038/s41592-019-0496-6。

[3] Yao et al., ReAct, ICLR 2023, arXiv:2210.03629；Shinn et al., Reflexion, NeurIPS 2023, arXiv:2303.11366。

[4] scikit-learn 模型/数据泄漏文档；OpenAI Python SDK；Pydantic JSON Schema 文档。具体 URL 见项目技术选型与消融方案。

资料查证由 GPT-6 Luna 辅助，后端实现由 GPT-6.1 Sol 辅助，主代理负责设计、审查和文稿；实验内部实际调用 gpt-6-luna。知识来源与适用范围保存在规则文件。