独立确认：每轨迹查询 30 条变体

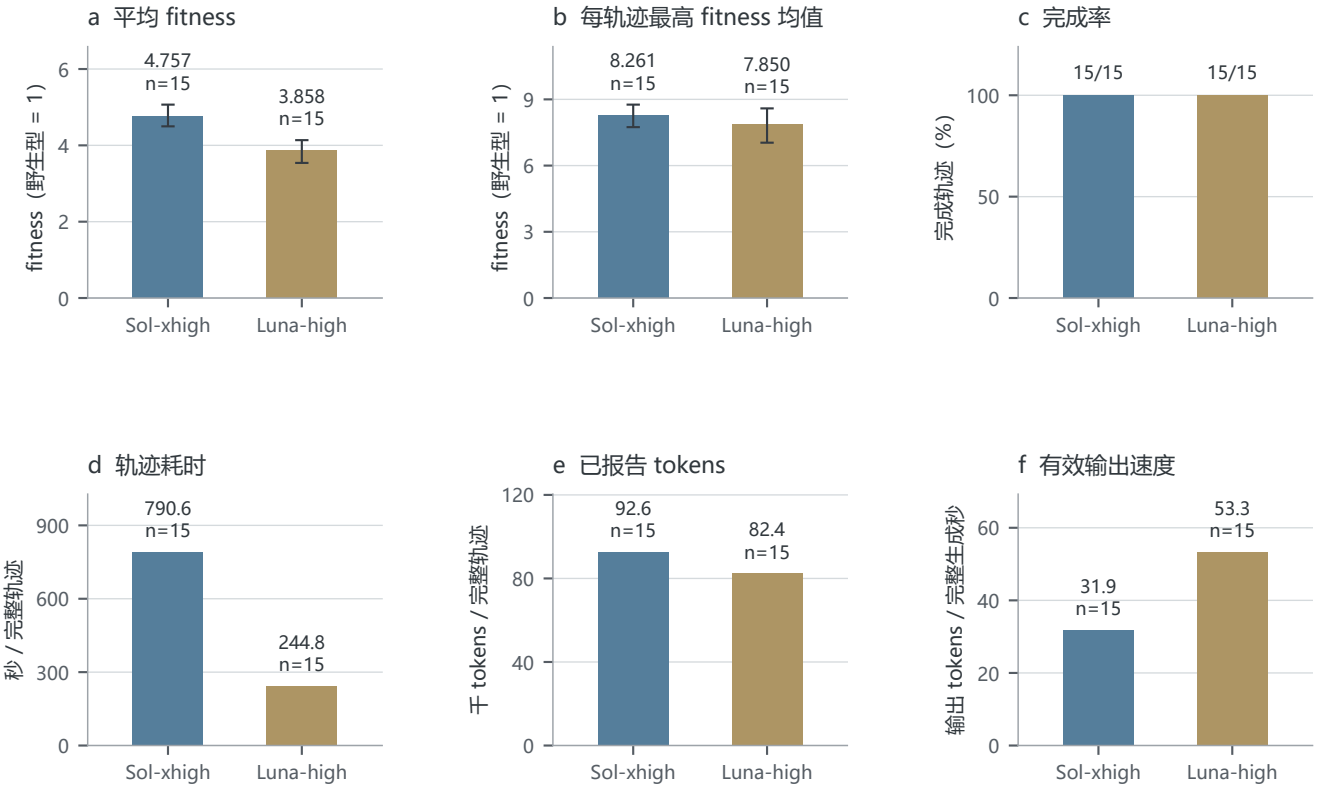

Sol-xhigh：GPT-6.1 Sol / first_n；Luna-high：GPT-6 Luna / reject

质量：各数据划分等权均值；误差线为 95% 分层 bootstrap 区间（5 划分 × 3 轨迹）。

成本与速度：完整轨迹的中位数；耗时不含共享准备。用量缺失：0 次调用、0 条完整轨迹。

速度：每轨迹输出 tokens 总量 / 完整生成总耗时，再取组中位数；包含思考和等待。